

SVM לא עובד עם יותר מ 2 קטגוריות

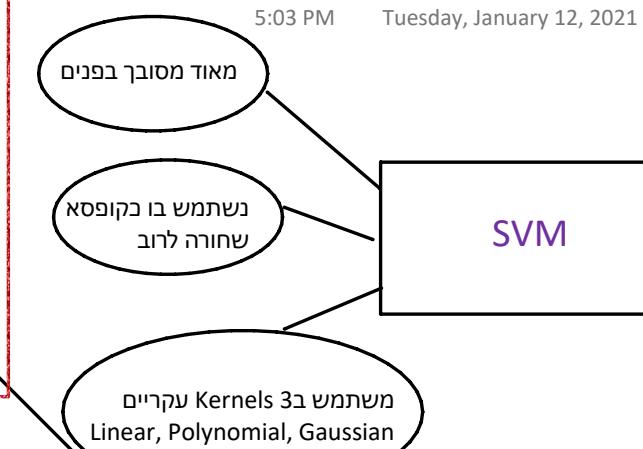
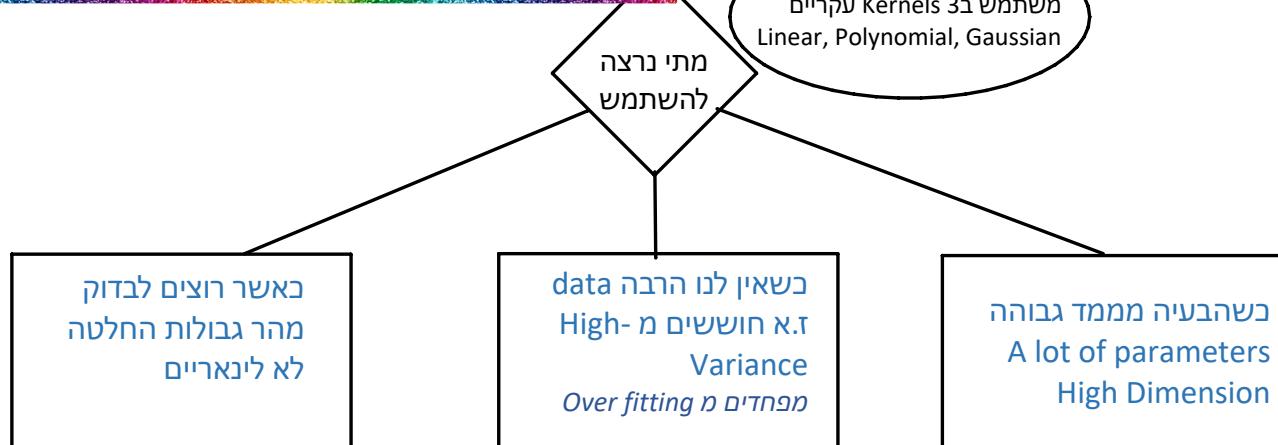
SVM גובנה עבור קלאסיפיקציה ביןארית ולא ניתן להרחבה בקלהות ליותר מ 2 קטגוריות

1. One VS One

- בונה $\frac{1}{2}(k-1)k$ קלאסיפירים : אחד לכל זוג קטגוריות
- בהינתן דוגמא x הפעל את כל הקלאסיפייר
- פلت החיזוי: הקטגוריה בעלת רוב החיזויים

2. One VS. Rest

- בונה k קלאסיפירים שմבדילים אם קלט x שייך לקטgorיה i או לכל יתר הקטגוריות
- פلت החיזוי: הקלאסיפייר שנוטן את הביטחון המקסימלי לקטgorיה שלו: (x, h_i) המקסימלי



אבל: קימות בעיות ביצועים כאשר D גדול מאוד
מטריצת ערך K (הקרנלים) היא ריבועית במספר הדוגמאות n
אם כן, ישן ואריאציות עבור קרנלים מסוימים שהמטריצה K לא תהיה ענקית

1. Support Vector Classifier (Soft Max Margin)

- Better generalization ability & Controlling bias-variance tradeoff
- Can be extended for regression
- Accessible and easy to use

2. The Kernel Trick

- Map data points to higher dimensional space in order to make them linearly separable.
- Since only dot product is used, no need to represent the mapping explicitly.
- Kernel Trick can be adapted to many parametric learning algorithms

3. Not a miraculous algorithm:

- Not very efficient to train when D is large
- Not very efficient to use at inference when number of support vectors is large
- Practically, when dimensionality is high, there are many support vectors
- Does NOT extend easily to multi-class
- Similar to other well established algorithms:
 - Logistic regression (possible with kernels)
 - Weighted-KNN)

Hinge Loss with L2 Regularization

בעזרת לוגרנגיאן ניתן להפוך את האילוצים לפונקציית loss ולחראות כי בעית האופטימיזציה הקודדרטיבית שקולה למצוער הפונקציה:

$$\underset{w}{\text{minimize}} \left\{ \sum_{i=1}^m \max[0, 1 - y_i h(x_i)] + \gamma \sum_{j=1}^n w_j^2 \right\}$$

- פונקציית loss - Hinge loss שמשמעה חירגות מ-1.
- $\max[0, 1 - y_i h(x_i)]$ גודלה מ-1 ה loss הוא 0.
- אם x בתוך המargin, loss=0.
- אם x בצד השני של גבול החלטה, loss>1.

Ridge Regularization:
Penalty γ controls bias-variance
in the same way as C

$$\text{for every } (x_i, y_i) \in D \\ y_i (wx_i) \geq (1 - \varepsilon_i) \\ \varepsilon_i \geq 0, \\ \sum_{i=1}^m \varepsilon_i < C$$

מסקנה: SVM שקול לביצוע GD על hinge loss עם גורלייזציה L2.
(בנהנזה ש GD אכן ימצא מינימום גלובלי)

90

SVM מתנהג בדומה לכמה אלגוריתמי למידה אחרים:
1. דוגמה לוגיסטיית עם גורלייזציה ridge kernel עם אותו Kernel Radial Kernel (Gaussian)

סביר שיהיה ב מבחן

SVM לינארי הוא כמעט זהה לגורלייזציה לוגיסטיית עם גורלייזציה אם מחליפים את loss -> CrossEntropy loss נשתמש ב GD על פונקציית loss שכוללת את hinge loss + Ridge loss ולקבל תוצאות דומות ל SVM

SVM זהה ל Gradient Descent אם נשנה את loss ל hinge loss + Ridge loss ונתממש ב Ridge

Support Vector Machine (SVM)

אלגוריתם פארמטרי שימושי ונגיש מאוד: הומצא ע"י תיאורטיקנים בשנות ה-90

נראה היה מסתורי, שונה ואפקטיבי מכל אלגוריתם אחר עד אותה תקופה:

- גרם לדיניה כמעט טוטאלית של רשותות נוירונים בשנות ה-90.
- לאט לאט התברר שהאלגוריתם אקוויולנט לטכניקות ידועות ב ML:

Support Vector Machine is a binary classifier

נבדיל במינוחים

Maximum Margin Classifier

קלסיפיר ביניاري לינארי על בסיס מיקסום המרווה (margin) בין הקטגוריות - דרוש כי הנתונים יהיו ניתנים להפרדה לינארית (בדומה לפרופטרון)

Support Vector Classifier

הרחבה לקלסיפיר ביניاري לינארי שאינו דרוש הפרדה לינארית מוחלטת, ומאפשר גם outliers.

Bias-variance tradeoff Capacity מאפשר שליטה על

SVM:

הרחבה לקלסיפיר ביניاري לא לינארי ע"י טרייק הernal

הHINGE הוא דואג שהחומר יהיה 1 קבוע, אך אם המרחק של נקודה מסוימת גדול מהמargine (1) אז אין שגיאה (נבחר 0 ב MAX)

הHINGE
המargine
הHINGE
 $\max[0, 1 - y_i h(x_i)]$

בתוב יפה בכחול בתמונה (משאייר כי אולי אתkan בהמשך)
אם חידנו שלילי, אבל באמת הוא חיובי, אז $(x_i)h_i$ ישילי. במקרה הזה $1 - (-num) > 1$

אם נקודות מחוץ ל margin בצד ההפוך: האסם יבחר בין 0 לבין הווודאות של הנקודה (היבטיו $(x_i)h_i$, יהיה גדול מ-1 או יבחר 0)

אם נקודה היא בתוך המargin בצד הנכון (היבטיו $(x_i)h_i$ יהיה בין 0 ל-1 או יבחר)

אם זה בתוך המargin אבל בצד הלא נכון (של גבול ההחלטה) השגיאה היא גדולה מ-1

שה"כ נמודד את השגיאות ונמוצע אותן בgradient descent

Why [-1, +1] ? Will help us with the math later..



Maximal Margin Classifier:

היפר-מישור מפריד C

בහינתן קבוצת אימון D של דוגמאות מסווגות בינהית $\{-1, +1\}$ מממד n ,
הניתנת להפרדה לינארית,
וחוצים למצוא היפר-מישור מממד $n-1$ המפריד בין הדוגמאות

אנחנו מניחים ש
ניתן להפרדה לינארית

במימד n היפר-מישור המפריד הוא אילוץ מהצורה :

$$h(x) = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n = 0$$

למשל: במימד 2, למישור המפריד צורה של קו לינארי $w_0 + w_1x_1 + w_2x_2 = 0$

כל נקודה שמקיימת את האילוץ, היא נקודה על המישור המפריד

נקודות מעל למישור יסוגו כ 1 : $w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n > 0$

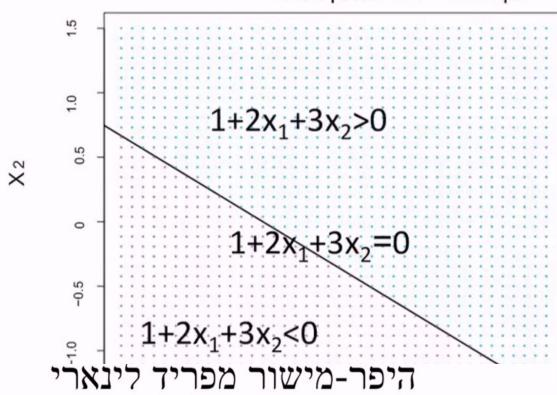
נקודות מתחת למישור יסוגו כ -1 : $w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n < 0$

הסיווג של x הוא : $\text{sign}(w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n)$

Hyper-plan $1+2x_1+3x_2=0$

נשים לב שפה אין הסתברות(בניגוד
ל _____), יש רק חיזוי (לפי ה sign של
ההיפוטזה (+ או -))

n במימד n ניתן להפרדה לינארית אם ניתן להعبر היפר מישור במימד $n-1$
המפריד בין נקודות + לנקודות - ללא יוצא מן הכלל.



דוגמה בשני ממדים

בහינתן קבוצת אימון D של דוגמאות מסווגות בינהית $\{-1, +1\}$
מסוגות בינהית $\{+1, -1\}$,
הניתנת להפרדה לינארית,

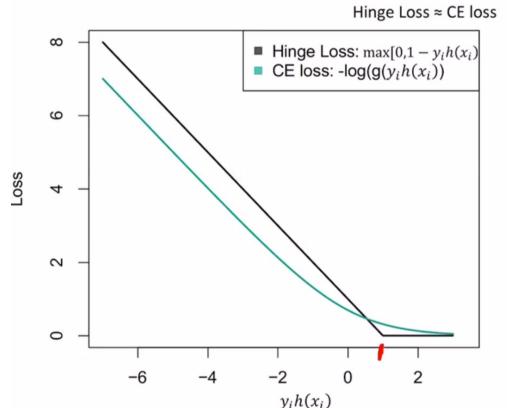
קשר הדוק בין SVM לרגרסיה לוגיסטיית

למישור המפריד יש את התכונה:

$$y_i h(x_i) = y_i(w_0 + w_1x_{i1} + w_2x_{i2} + \dots + w_nx_{in}) > 0$$

המרקח של נקודה x מהמישור נותן יינדיקציה לרמת הביטחון בסיווג:

$$\frac{y_i(w_0 + w_1x_{i1} + w_2x_{i2} + \dots + w_nx_{in})}{\sqrt{\sum_{j=1}^n w_j^2}}$$





0:17:00

היפר-מישור מפריד לינארי

$$x_i = (x_{i1}, x_{i2}, \dots, x_{in})$$

מסווגות בינהירות $\{+1, -1\}$
הניתנת להפרדה לינארית,

למיישור המפריד יש את התכונה:

$$y_i h(x_i) = y_i(w_0 + w_1 x_{i1} + w_2 x_{i2} + \dots + w_n x_{in}) > 0$$

המרחק של נקודה x מהמיישור נתון אינדיקטיה לרמת הביטחון בסיווג:

$$\frac{|y_i (w_0 + w_1 x_{i1} + w_2 x_{i2} + \dots + w_n x_{in})|}{\sqrt{\sum_{j=1}^n w_j^2}}$$

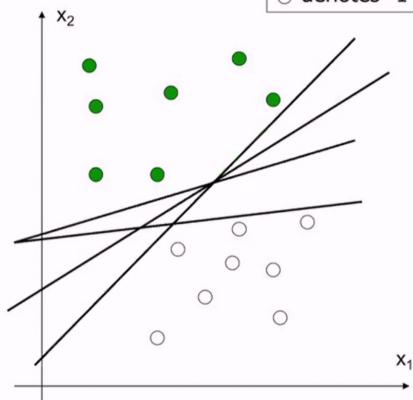
מרחק מנקודה למיישור
חלוקת בnormה

ישנם אין סוף מיישורים המקיים את האילוצים (לכל נקודה). באיזה נבחר?

ברגסיטה לוגיסטי בחרנו מיישור מפריד שմזער את הCE, עבור SVM נפוץ לוגיקה אחרת

היפר-מישור מפריד לינארי

● denotes +1
○ denotes -1



- Which one is the best?

Large Margin Linear Classifier

● denotes +1
○ denotes -1



Pg.4

בשלושה ממדים - גליל \ צינור , בח ממדים היפר צינור

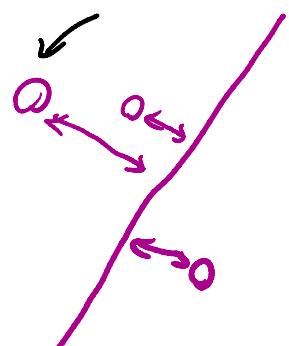
אם נכפיל את החזיו בתוצאה של
ההיפוסזה נקבל תמיד משזה שגדל מ-0

כפי אם זה גדול מ-0 אז סוויגנו את זה ב+

אם זה קטן מ-0 סוויגנו ב-

ההפליה תצא חיובית בכל מקרה

ויתר כל כך



למקסם את המargin
למקסם את המargin לח הנקודות
הכproximity

למה?
זה מודיד Variance

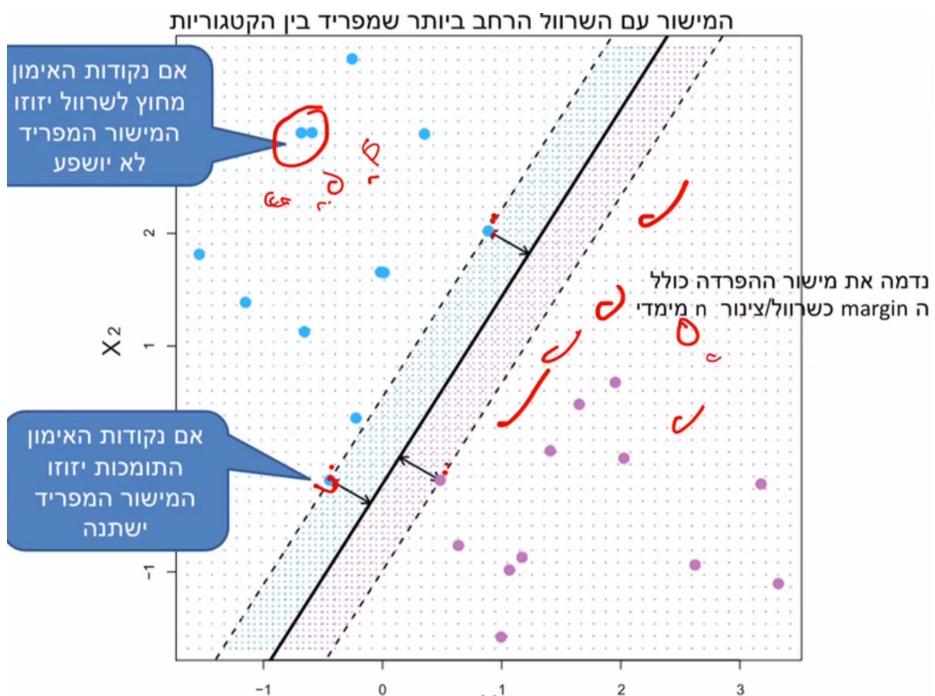
AIR בוחרים את הנקודות
נמקסם את רוחב המלבן

למקסם את החזיו
למקסם את המargin לח הנקודות ה-
proximity

למה?
זה מודיד Variance

הנקודות הרוחקות מהקו בכלל לא משפיעות על גבול
ההחלטה, הן יכולות להשתנות ולהתווסף וזה לא ייזד בולם

AIR בוחרים את השרוול של SVM



:Max Margin Classifier

בעייה אופטימיזציה קוודרטית

- Maximize M

$M(w_0, w_1, w_2, \dots, w_n)$, w_i are the params that effect M

המטרה:

למצוא את המשקלות w
שimaxmo את M

- subject to $y_i (w_0 + w_1x_{i1} + w_2x_{i2} + \dots + w_nx_{in}) \geq M$
for every $(x_i, y_i) \in D$

האילוץ,
המרחק של כל הנקודות בס ממרכז הצינור
יהיה גדול מ M

- Subject to $\sum_{j=1}^n w_j^2 = 1$

ישנו הרבה מישור מפרידים אקוואלנטים
(כל הכפלת משווהת המישור קבוע).

- בוחר מבין כל המישורים זהה עם גורם אחד,
- נתן משווהות $w_nx_{in} + w_1x_{i1} + \dots + w_0$: המרחק של הנקודה מהמישור
- הבעיה מנוסחת כך שהפיתרון הוא גלובלי ויחיד**

לדוגמה:

$$2x+5$$

הוא אותו מישור כמו

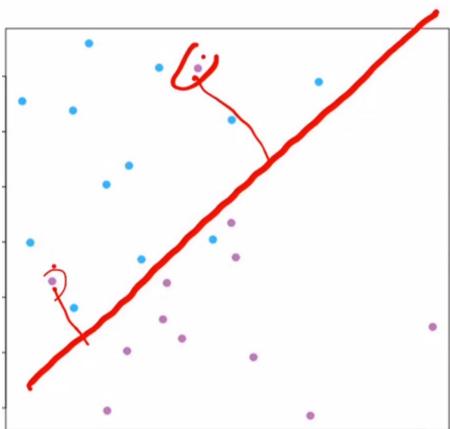
$$4x+10$$

ויש אינסוף מישורים באלה
(כל הכפלות)

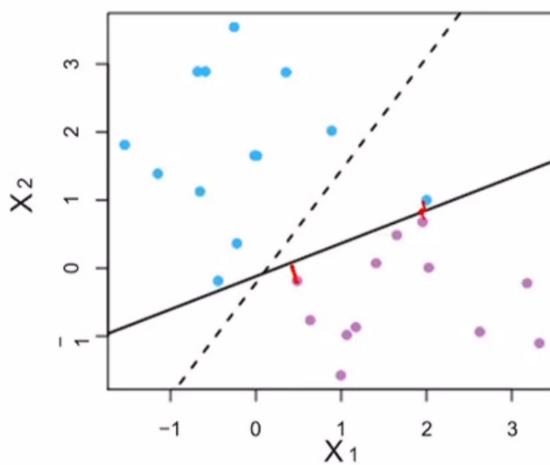
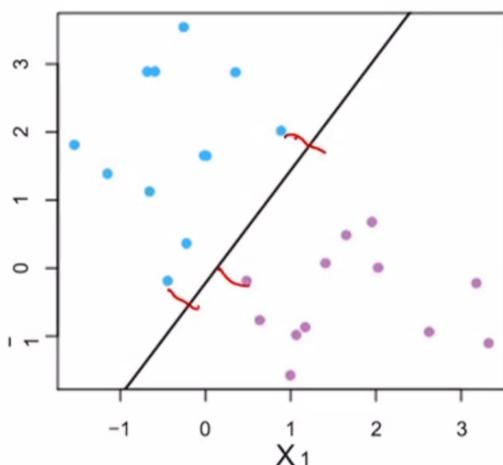
33:30

בחלק מהספרות מתארים את הבעיה באופן הבא:
אנחנו מ Chapman מchapisms M יחיד, ואנחנו מchapisms את המשקלות המינימאליות
[שומרים על אחד ומוחזרים את סכום המשקלות]

כשנקודות אינן ניתנות להפרדה לינארית, אין פתרון
לבעית האופטימיזציה.
Max Margin Classifier פשוט לא קיים



תוספת של נקודה אחת עלולה לגרום לתזוזה דרסטית של המישור המפריד
ולmargin צר מאד. אינדיקציה ל Over-fitting



Max Margin Classifier - Problems

- אם הנתונים לא ניתנים להפרדה לינארית,
אין פתרון לבעית האופטימיזציה.
הגדרת הבעה אינה מאפשרת outliers בכלל!
- גם אם ניתן להפריד, **ישנה רגשות גבוהה לנקודות שבוחזית** (בสมור למישור המפריד). שינוי במקומות וקטורי התמיכה, כמו תוספת נקודות גבולות ה *chin* יכול לגרום לשינוי דרמטי במישור המפריד ול **חומר צר מאד**

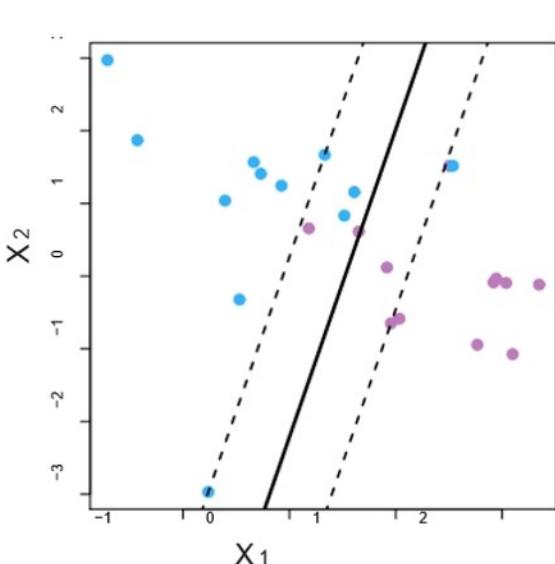
לא דרש הפרדה לינארית מלאה - Support Vector (Soft) Classifier

נחשף Margin Classifier **Soft**

כיצד?

- נאפשר: מיעוט דוגמאות תוכננה להופיע בצד הלא נכון של $h(x)$ מוביל להצ'ר אותו
- נאפשר: מיעוט דוגמאות תוכננה אפלו להופיע בצד הלא נכון של מישור הפרדה מבלי שיפשו על מישור הפרדה ואפלו על ה $h(x)$ (ז.א. לא נדרש הפרדה לינארית מושלמת)

על מנת לבצע קלאסיפיקציה טובה בנוכחות outliers ורעש, רצוי לאפשר פרדייקציה שגיה לפעם



- נרוות:
- ϵ רוחב ייחד עם קלאסיפיקציה טובה של רוב דוגמאות האיכון
 - סבילות Outliers Robustness בודדים
 - אפשר רב יותר של נקודות support – התוצאה: פחת ריגשות לIALIZEDות ונקודות חדשות

אינטואיציה:

כיצד מגדרים זאת כבעית אופטימיזציה?
רוצים למקסם את ה $margin$ אבל עברו
margin רוחב מוכנים מוכנים "לשלם" שמייעוט
נקודות יכנסו לתוך הциינור ואפלו יסוגו כשלגים

Support Vector Classifier = Soft Margin Classifier

נוסיף משתנים לבועית האופטימיזציה

נוסיף ϵ Slack variable ϵ_i לכל דוגמה, אשר מאפשר לה להופיע בצד הלא נכון: ϵ_i הוא התשלום שמשלים עבור חריגה מה Margin (נרצה למזער את סכום התשלומים)

- כאשר $\epsilon_i = 0$ הדוגמא תהיה מחוץ לmargin (תסוג נכון)
- כאשר $0 < \epsilon_i \leq 1$ הדוגמא תהיה בצד הלא נכון של margin אבל בצד נכון של המישור (תסוג נכון)
- כאשר $\epsilon_i > 1$ הדוגמא תהיה בצד הלא נכון של המישור המפריד (תסוג שגוי)

ולא יתווסף דבר לסכום המוגבל ב C
במקרים אלה יתווסף לתוך המוגבל ב C

יהיה לנו תקציב C שאחמנו מוכנים לשלם עבור הנקודות החורגות הללו:
כל שהחריגה גדולה יותר, התשלום יהיה גדול יותר.

ככל שנגדיל את C הירוח קטן
(כמו לעשות רגוליזציה)

נרצה להרחב את margin כמה שיותר, אך ובשים פנים לא לצאת מהתקציב

כפי אנחנו לוקחים Margin יותר גדול
ומספר הנקודות שתומכות יותר קטן,
בכה שגם אם אחת מהן תזוז מעט,
תהייה השפעה גדולה

Maximize M

$M, w_0, w_1, w_2, \dots, w_n, \epsilon_i, \dots, \epsilon_m$

Subject to: for every $(x_i, y_i) \in D$ המבחן של כל נקודה ב Training Set גודל גזע

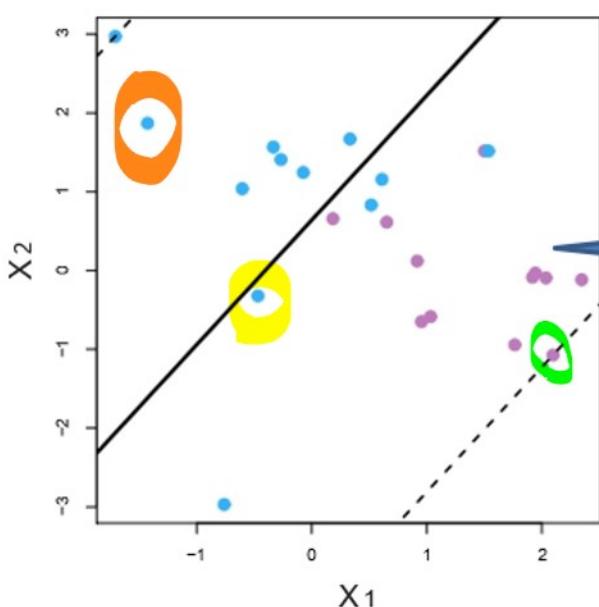
- $y_i (w_0 + w_1 x_{i1} + w_2 x_{i2} + \dots + w_n x_{in}) \geq M(1 - \epsilon_i)$

- $\epsilon_i \geq 0,$

- $\sum_{i=1}^m \epsilon_i \leq C$ סכום כל ה ϵ_i יהיה קטן מהתיקציב C

- $\sum_{j=1}^n w_j^2 = 1$ האילוץ על הנורמה שאראים קודם (שתיהן בגודל 1)

ניסוח בעית האופטימיזציה

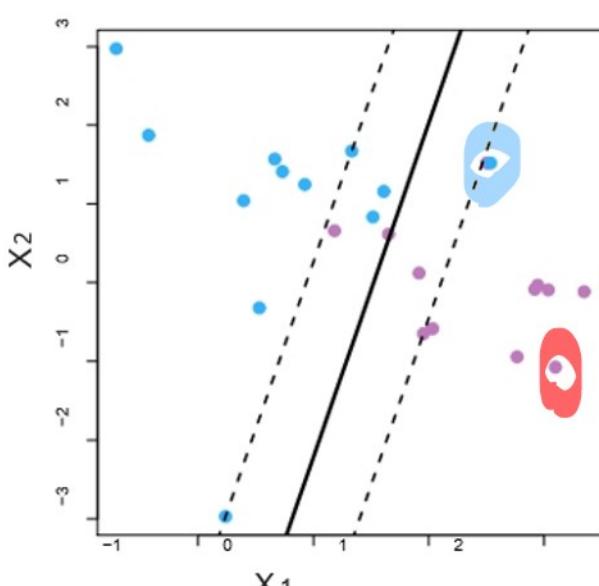


C. גדול אפשר margin רחב:
מספר גדול של נקודות תמייה,
ואירוען קטן

1. ϵ_{yellow} בצד הירוק, לא רחוק מגבול ההחיליטה

2. ϵ_{green} בצד הירוק, טיפה בתוך margin

3. ϵ_{orange} בצד הירוק, רחוק כמעט מהגבול



C. קטן אפשר רק margin צר,
מספר קטן של נקודות תמייה,
ואירוען גדול

1. ϵ_{blue} בצד הירוק, יצא מהmargin אבל ממש קרוב אליו

2. ϵ_{red} בצד הירוק, מחוץ לmargin

- C: גבוה אפשר margin רחב הבני על הרבה וקטורי תמר
 - למחרות שחיי הרבה דוגמאות שיפורו את המargin.
 - מספר וקטורי התמר גדול ולפיכך פחות ריגשות לשינויים בוקטוריו התמר
 - (פחות שגיאת ואריאנס)

נקודות התרמן

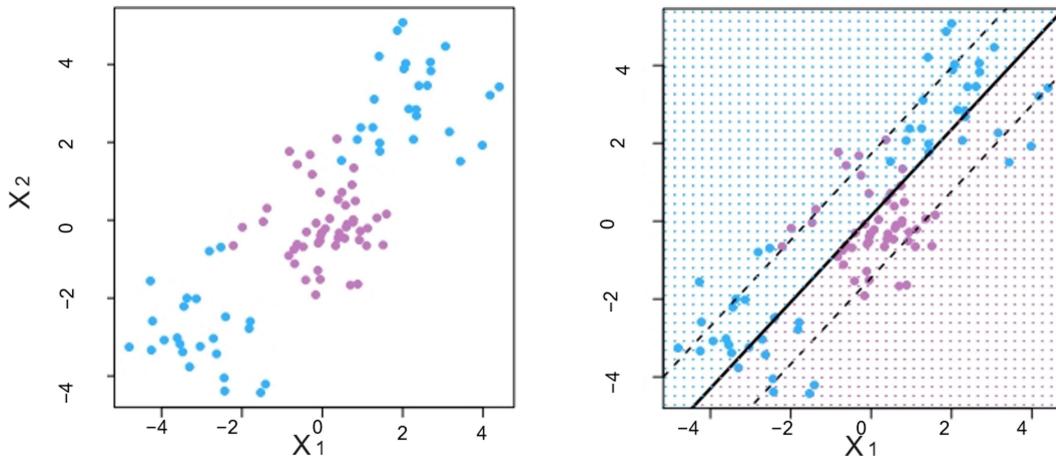
- נקודות מחוץ ל margin אינן משפיעות כלל על המישור המפריד. אפשר להוציאם, או להזיזם כל עוד לא הופכות לנקודות תמר מבלתי לשנות את המישור ואת ה margin
- נקודות בתחום גבולות ה margin הם נקודות תמר:
 - שינוי בהם עלול לגרום לשינוי במישור המפריד גם ב margin. (ככל נקודות שחציו את גבול ה margin לצד הלא נכון).
 - אם מספר נקודות התרמן קטן, שינוי קל במקומם עלול להשפיע דרסטית, מה שਮעיד על Over-fitting.

לפעמים נקראות גם: הנקודות שבחזית, או הנקודות "שמחזיקות" את היפר-צינור ה Margin

Kernels Linear, Polynomial , Gaussian

ביצד נתמוך עם גבולות לא לינאריים?

SVC ימצא פתרון ג clues



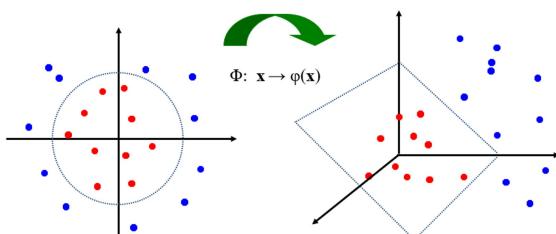
זכרו: הסבת מרחב ה feature (למשל: לקואורדינטות פולריות, או למרחב פולינומיAli)

אפשר גבולות החלטה לא לינאריים (על המרחב המקורי)

KERNELS מוצאו שיטה טובה (שמסתבר שעובדת טוב גם לאלגוריתמים אחרים) לשימוש את אותו הדבר, רק בצורה יותר יעילה חישובית (מאשר להסב \ להעלו ממדים \ גאוסיאניים)

- אפשר שנוסיף polynomial features: quadratic/cubic/k-order...
וביצוע את האופטימיזציה במרחב מממד גדול יותר
- אפשר להשתמש במאפיינים לא דווקא פולינומיAliים

הרעין הכללי: ניתן למפות את מרחב הקטליטים למרחב מממד גבוה יותר שם הנתונים כן ניתנים להפרדה לינארית



Pg.9

מספר האפשרויות עצום ואם לא נזהר יהיו בעיות חישוב!

SVM משתמש ב"טריק ה Kernel" שמאפשר הרחבת המרחב בו משתמש ה SVM Classifier בائفו שהוא "בהרבה מקרים" יעיל יותר מבחינה חישובית
וללא המרה בפועל של הווקטורים

דוגמאות ל kernels פופולריים

1:12:00

קיים המונח kernels, כמעט לכל מטרה,
למשל kernels להשווות דמיון בין גרפים....
אבל ה-3 הללו הם הכל פופולריים

Examples of Kernels

Linear: $K(x, x') = x \cdot x'$

מדוע SVM עם linear kernel יהיה טוב יותר
מן פרטיטורן או מ-naïve Bayes?
הרבה בעיות למדידה היחסים – בymiדים גבוהים.
למשל סיווג טקסטים.
כשהממד גבוה, אפלוי Overfitting (למשל כאשר מילא
אקריאת הינה קורלטיבית עם סיווג מסוים)
אלא SVM ומתאים במיוחד
לymiדים גדולים

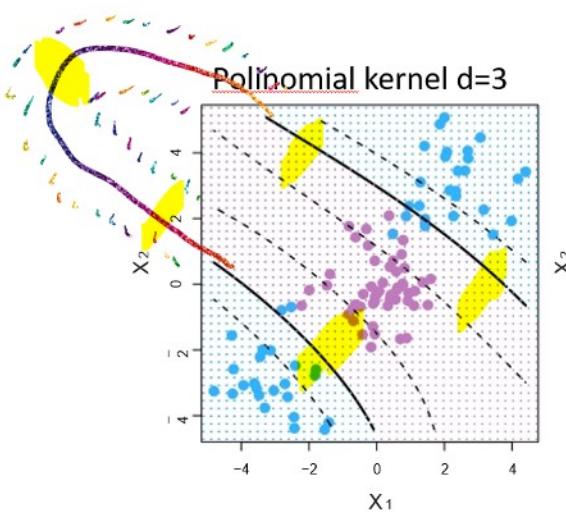
Polynomial: $K(x, x') = (x \cdot x')^d$

Kernel Polynomial Kernel גם בצורתו הכל פשוטה
 $d=2$ נותן הרבה יותר.

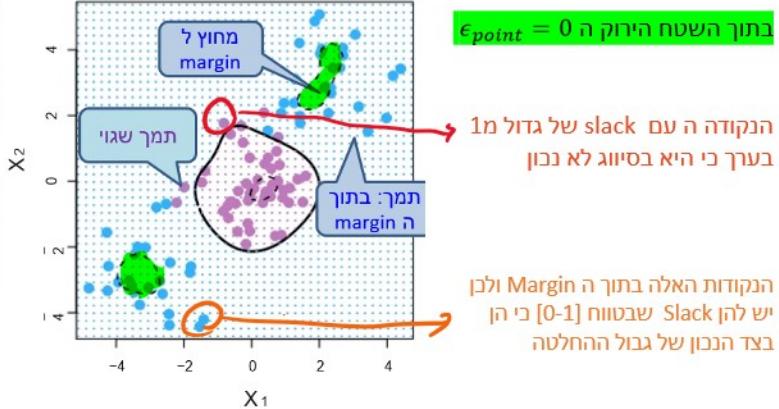
Gaussian: $K(x, x') = \exp(-\frac{1}{2}\|x - x'\|^2/\sigma^2)$

Kernel גאוסיאני: דומה ל RBF נתון דימינון בעל צורת פעמון.
מעלים בדקה את הנורמה (מרקח אוקלידי ביריבוע) ומחלקים ברוחב
ה kernel. כל שהסיגמא קטנה, הגאוסיאן ציר יותר (low-bias, High-variance)
כל שהסיגמא גדולה, הגאוסיאן מישר יותר (High-bias, low variance)
פונקציית הדימינון הופכת להיות מרך אוקלידי (High-bias, low variance)
סיגמא: היפר פרמטר

אם נראה שאגואסיאן זה הוא מכפלה
סקלרית של 2 טרנספורמציות?
זכרו שמספר features יכול להיות
בטרנספורמציה:
אבל לא עושים פעולה את הטרנספורמציה-
מחשבים רק את K שימושו היא כמו
מכפלה סקלרית של 2 טרנספורמציות



Radial kernel



יתרונות חישוביים ב kernels

- אין צורך לעבור למרחב הגדול. מספיק לחשב את הדימינון בין כל זוגות הנקודות (במקרה הגרוע $\Theta^{(2)}$)
המעבר למרחב הגדול נעשה באופן לא מפורש implicit.
יתרון גדול כי בהרבה אפליקציות המרחב הגדול הוא עצום
- בזמן אימון צריך לחשב את הדימינון של כל הזוגות אך בזמן חיזוי לנקודה x מספיק לחשב את הדימינון
שלה רק לוקטור התמר
- ה Kernel מאפשר features לעבור טרנספורמציה, אבל נשארת הפשטות והקלות של העבודה
הילינארית אחרי הטרנספורמציה

(לפעמים המרחב המוגדל הוא מממד אין-סופי ואז אין בכלל אפשרות להעביר את הבעיה למרחב הגדול בצד אחד – במקרה של radial kernels)

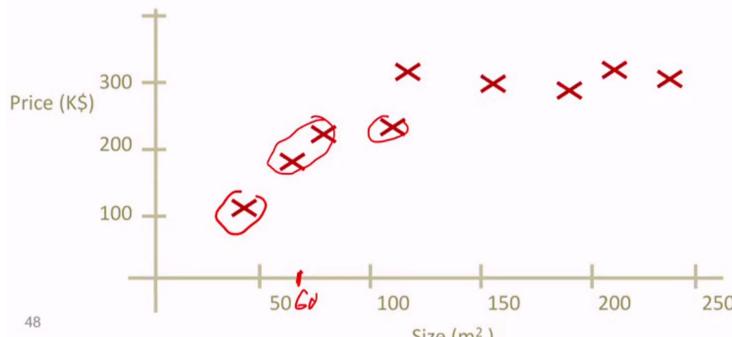
שיטה להוסיף דרגות גמישות למודל (מלחמה בוגינג) Under-Fitting (Under-Fitting).
במקום שנחה ערך חדש לפיקוח על המידוע שלנו (זמן האימון), ונכח ערך חדש לפיקוח.
נשתמש בשיטה זו: Locally Weighted Linear Regression (LWLR).
בעבור כל פעם קו בהתאם לקרבה לנקודה החדשה.

שליטה על הORITY על הגמישות ברגסיה לינארית:

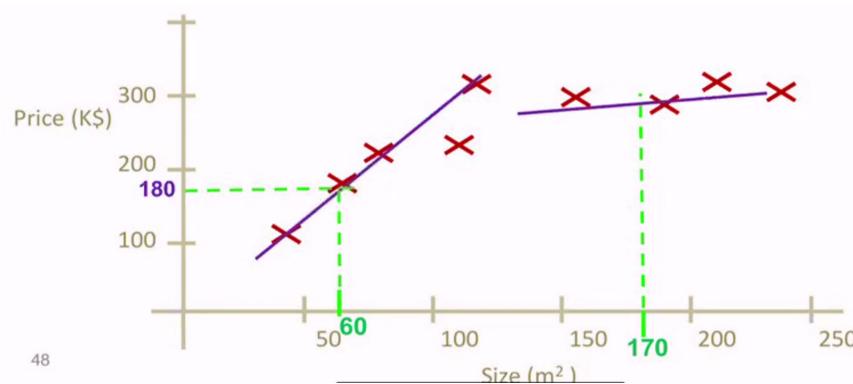
- Locally Weighted Linear Regression
- לא נבנה מודל בזמן האימון, אלא נחכה ל query

בהתנן Query (ווקטור מאפיינים X)

בבנה מודל ורגסיה בר' שהנקודות ב ס
הקרובות יותר ל X ישפיעו על הרגסיה
יותר מהנקודות הרחוקות ממנו



קל בAIMONIM - קשה בקרוב



בזמן האימון רק שומרים בזיכרון את הדוגמאות

בזמן החידוי יוצרים קו גרסה לנארו מחרקוות הקרוובות ביותר לקלט

החווןנות ה-

1. לוקח הרבה זמן להוציא פרדיקציה
2. לא מתאים big Data

היריד של שיטה לא פרמטרית ביחד עם רגרסיה ליניארית לוקאלית
אימון: שומרם בזיכרון דוגמאות ומשתמשים בהם בכל פעם שזקוקם לחיזוי
חיצוני.

ה β היא משקל שאנו
נתנים לכל ב�ן Training set

בטא תלואה במרקח (המשקול)
בין הנקודה החדשה, לבין
נקודה ב training set שלנו D

שגיאות בנקודות קרובות ה חוויות

שגיאות בנקודות רוחקות ה פחות חשובות

ז - שולחת על הגמישות

$$WMSE_w = \frac{1}{2m} \sum_i \beta_i (\mathbf{w}\mathbf{x}_i - t_i)^2$$

דוגמה לפונקציית דימוי:

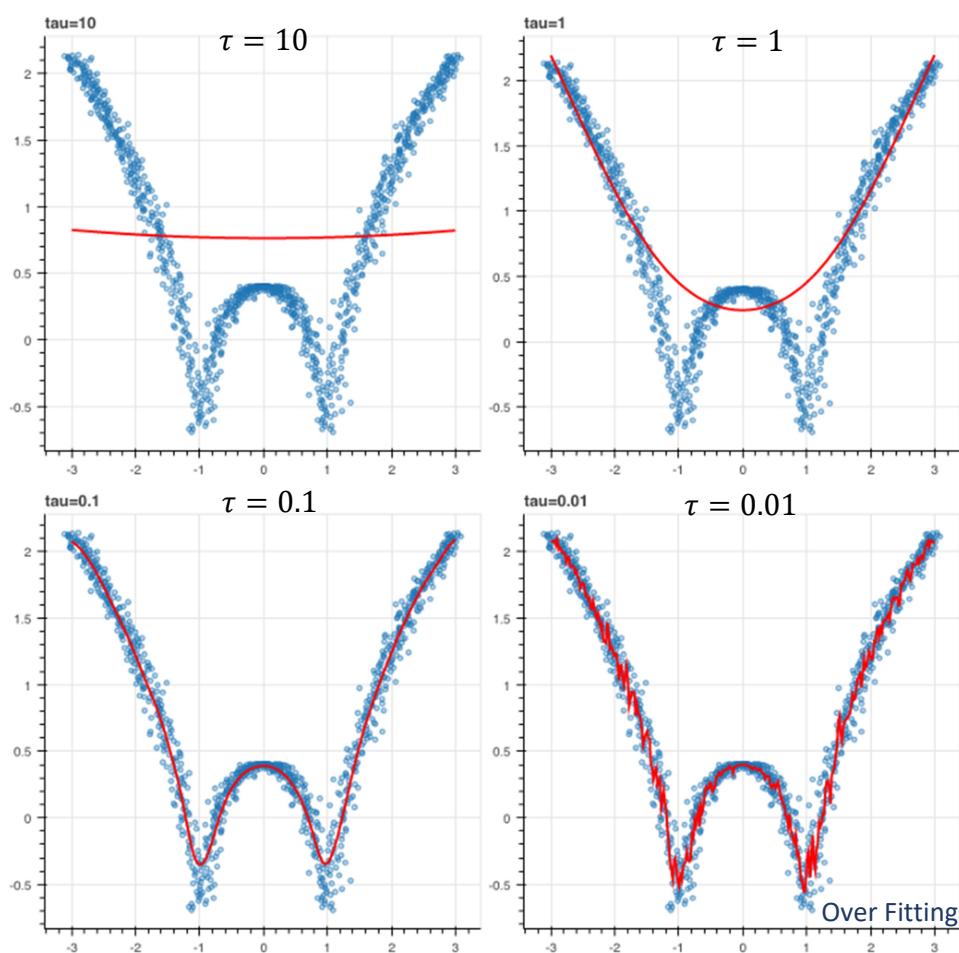
מרקם מחושב ע"פ הפונקציה הגאומטרית מסביב לנקודה:

$$\beta_i = e^{\frac{-||x_i - x||^2}{2\tau^2}}$$

- ככל ש ז' קטע: מרחוקים גדולים מקבלים משקל אפסי

(ורק נקודות קרובות מאוד משפיעות)

- ככל ש גודל יותר כך נלקחות בחשבון גם נקודות רוחקות



ניתן לשולט על הגמישות
בעזרת פונקציית המשקל:

$$\beta_i = e^{\frac{-||x_i - x||^2}{2\tau^2}}$$

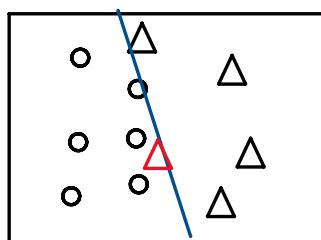
כל שטאו קטן יותר
המשקל של נקודות
מרוחקות שואף ל-0.
הנקודה היכי קרובה
משפיעה הרבה.
שטאו גדול מאוד כל
הנקודות משפיעות באופן
דומה ומקבלים גרסה
לינארית רגילה

גרסה קיימת גם ל-W
די דומה ל-KNN

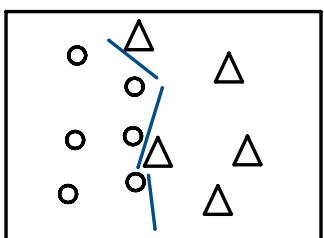
הערה:

את אותה טכניקה שימושיפה גמישות אפשר לעשות לוגיסטיית (לוגיסטיקה).

אם יש לנו למשל את המצב זהה:



קו רגיל לא יצילח



אבל נעשה לפיה נקודות קרובות איז נוכל להפריד

(לא כ"ב מתקבל כי גרסה לוגיסטיית צריכה GD
ו-GD יותר בבדה מההה Normal Equasion, אך NE בiamiדים קטנים הוא מאוד מהיר, בעוד שGD צריך לעשות הרבה איטרציות.
אז בغالל השיטה העצנית של "קל באימונים, קשה בקורס", אנחנו נctruck משהו מאוד מהיר בזמן query.